

INOVAÇÃO, EMPRENDORISMO E LIDERANÇA

Gabriela Gonçalves (gmc@isep.ipp.pt)

MESTRADO EM ENGENHARIA INFORMÁTICA



ANÁLISE DE DADOS

MESTRADO EM ENGENHARIA INFORMÁTICA

Análise dos dados



Dados

Elementos que estão na base da produção do conhecimento

Serão transformados, estruturados, classificados e analisados

Análise

Observação e interpretação do fenómeno

Tem como objectivo extrair conhecimento utilizando para o efeito um conjunto de ferramentas

Processo de análise



Dados

Dados Estruturados

Conhecimento

Manipulação
Transformação
Codificação
Criação

Data Mining
Machine Learning
Operational Research

Apoio à Decisão

Eventuais questões de Big Data

Objectivos Negócio

Big Data



- **Volume –** Enorme variedade de fontes de informação fazem crescer a quantidade de dados armazenados.

- **Velocidade –** A necessidade de lidar com dados em tempo real cujo volume é significativamente grande.

- **Variedade** – Os dados podem ser obtidos em diversos tipos de formatos, por exemplo, dados estruturados, documentos de texto não estruturados, e-mail, vídeo, áudio, etc.

- **Variabilidade** – Fluxo de dados pode ter picos de carga (sazonalidade).

- **Complexidade** – A variedade e da diversidade de fontes de informação torna complexa a tarefa de depurar, transformar e relacionar o dados.

Big Data

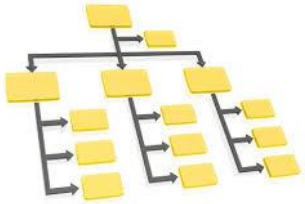


Ter mais dados não significa ter mais conhecimento. O importante é encontrar uma forma de extrair todo o conhecimento possível que está implícito nos dados.

É fundamental saber o que fazer com os dados

Big Data não é um problema, é uma oportunidade

Estrutura dos dados



Preparação dos dados

Análise dos dados

- Qualitativas
- Quantitativas
- Mista

Modelos a considerar

- Discretos
- Contínuos

Tipo de relatórios a produzir

Objetivos a alcançar

+

Regras do negócio

Preparação dos dados



Novas variáveis obtidas por combinação numérica de outras

Transformação de variáveis para obtenção de outros tipos de informação

Análise de componentes principais | Análise de Cluster´s | Análise categórica

Atribuição de códigos para parametrização de variáveis

Análise sumária (descritiva) dos dados para identificação de alguns indicadores

Variabilidade | Outliers | Distribuição | Correlações

Validação dos dados

Definição da base de dados

Objetivos da Análise dos Dados



Descritiva

- Indicadores estatísticos
- Tabelas de contingência

Inferência

- Estimação pontual
- Estimação intervalar
- Testes de hipótese

Previsão

- Regressão
- Séries cronológicas

Conhecimento

- Extração de conhecimento
- Classificação
- Aprendizagem

Estatística descritiva



Indicadores estatísticos

Ajudam a compreender a realidade e iniciar o processo de análise de dados

Medidas de tendência central

Média

Moda

Mediana

Medidas de dispersão

Variância e desvio padrão

Erro quadrático médio

Medidas de correlação

Pearson

Spearman

Dicotómica

Tabelas de contingência

Permitem relacionar duas ou mais variáveis categóricas através da frequência de ocorrência

Modelos – Inferência



Método científico para obtenção de conclusões sobre parâmetros de uma população a partir da recolha, tratamento e análise dos dados de uma amostra

Estimação

Pontual | Por intervalos

Testes de Hipótese

Tomar decisão sobre se o valor de cada parâmetro em análise pertence, ou não, a um domínio especificado pelo investigador

Modelos – Inferência



Estimação

Seleção do estimador

Justo – A valor esperado para o estimador é igual ao valor do parâmetro que está a ser estimado

Consistente – A variância do valor do estimador tende para zero com o crescimento da amostra

Estimação pontual

Procura estimar o verdadeiro valor dos parâmetros (desconhecidos) da população

Estimação por intervalos

Procura um intervalo de valores plausíveis para cada um dos parâmetros (desconhecidos) da população

Este intervalo designa-se por intervalo de confiança e está associado à probabilidade de nele encontrar o parâmetro populacional que está a ser analisado

Modelos – Inferência



Testes de Hipótese



Identificar os parâmetros de interesse pelo contexto do problema

Especificar a hipótese nula

Especificar a hipótese alternativa (o que pretendemos demonstrar)

Escolher o nível de significância

Escolher a estatísticas de teste adequada

Decidir sobre a rejeição, ou não, da hipótese nula.

- Avaliação do intervalo de confiança
- Determinação da potência do teste
- Análise dos erros tipo I e tipo II

"Hipótese é uma coisa que não é, mas a gente faz de conta que é só para ver como seria caso ela fosse."

Jô Soares

Modelos – Inferência



Tipos de testes

Paramétricos – são usados quando a variável dependente é definida em escala intervalar. A utilização deste tipo de testes exige que sejam satisfeitos os seguintes requisitos:

Os dados são do tipo intervalar (Intervalos contínuos e de igual amplitude)

Os dados seguem uma distribuição normal

As variâncias são homogéneas

Não paramétricos – são usados quando a variável dependente é definida em escala ordinal ou nominal, nos casos em que não se verifiquem os pressupostos para os testes paramétricos e em amostras de pequena dimensão (menos de 31 elementos)

Modelos – Inferência

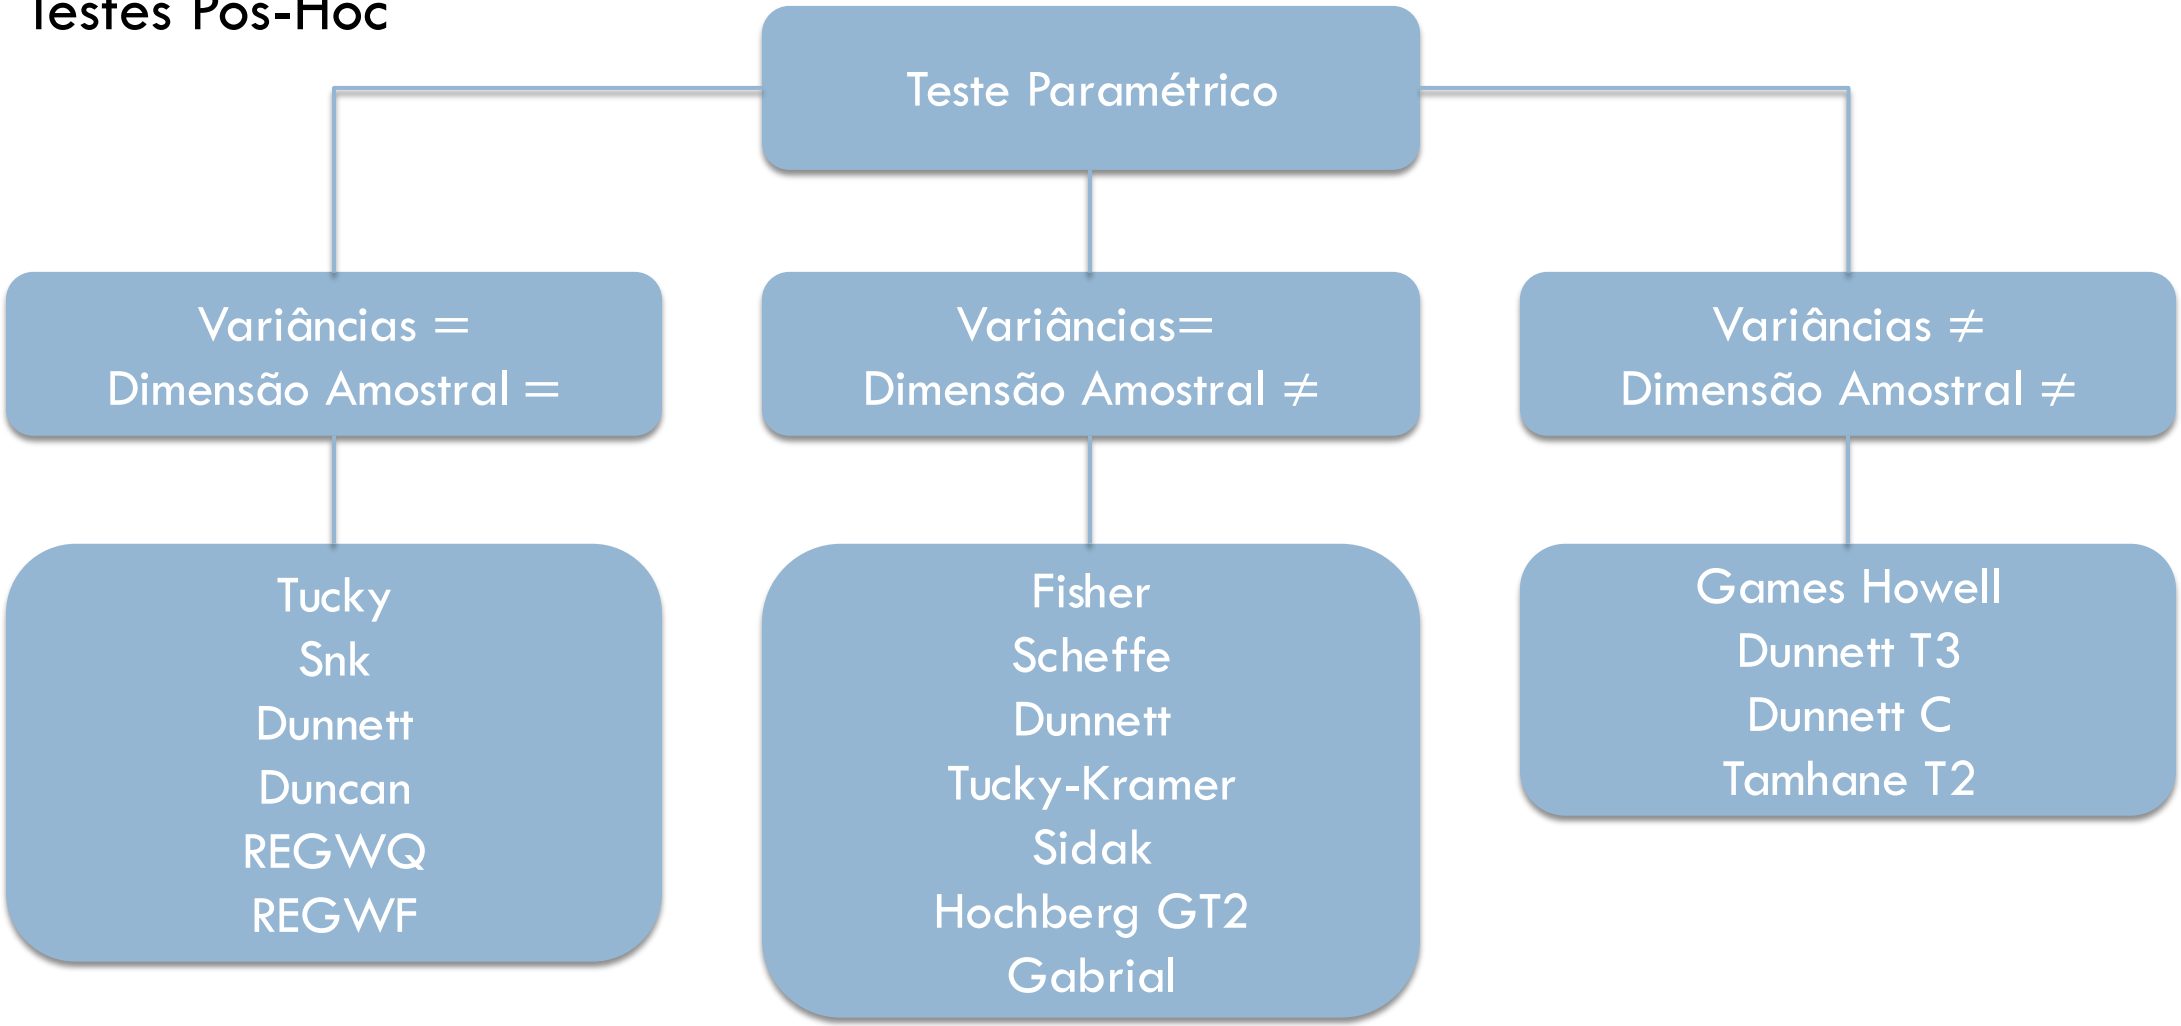


Objectivo do teste	Variáveis contínuas e populações normais	Variáveis contínuas ou populações não normais	Variáveis binomiais
Descrever um grupo	Média e Desvio Padrão	Mediana e amplitude interquartil	Teste de proporção
Comparar um grupo com um valor	One-sample t_teste	Teste de Wilcoxon	Teste de Chi-quadrado / Teste binomial
Comparar 2 grupos independentes	Independent sample t_test	Teste de Mann-Whitney	Teste de Fischer
Comparar 2 grupos emparelhados	Paired sample t_test	Teste de Wilcoxon	Teste de McNemar
Comparar mais de 2 grupos independentes	ANOVA 1 factor /ANOVA 2 factores	Teste de Kruskal-Wallis	Teste de Chi-quadrado
Comparar mais de 2 grupos emparelhados	ANOVA para medidas repetidas	Teste de Friedman	Teste de Cochran

Modelos – Inferência



Testes Pos-Hoc



Modelos – Inferência



Testes Pos-Hoc

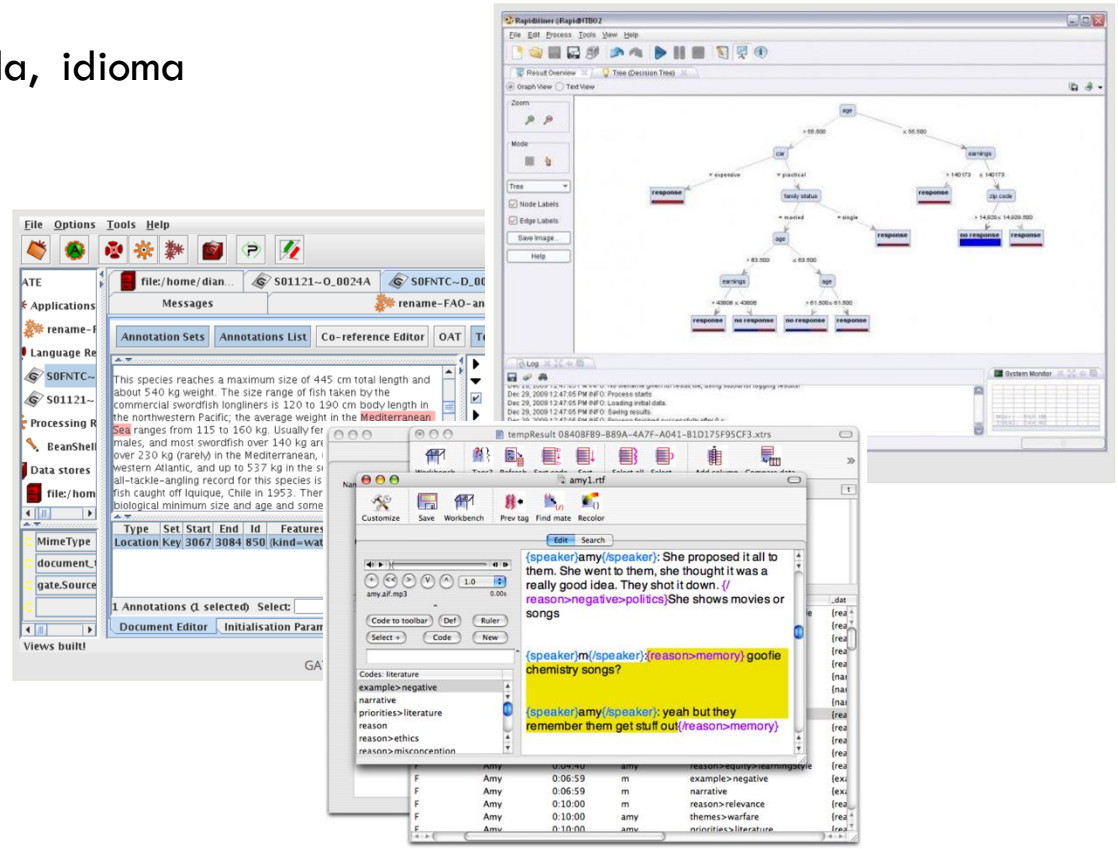
- Teste Não Paramétrico
  - Por ajustamento do valor de prova
    - Bonferroni
      Holm
      Holland&Copenhaver
      Hommel
      Hochberg
      Rom
  - Dimensão Amostral ≠
    - Nemenyi
      Dunn control
      Steel Dwass
      Stell Control
  - Dimensão Amostral ≠
    - Dunn Pairwise
      Dunn Control

Software



- **Free Software**
  - QDA Miner Lite
  - GATE – General Architecure for Text Engineering
    - Processamento de linguagem natural (não tem, ainda, idioma português)
  - TAMS Analyzer (for Macintosh)
  - R (package tm)
  - Rapide Miner
  - Weka
  - Python
  - Orange
  - Knime

- **Not Free Software**
  - NVIVO
  - SPSS
  - SAS
  - SmartPLS



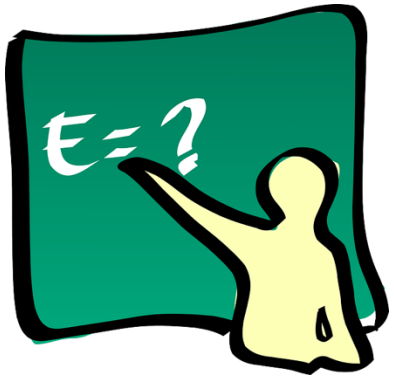
Apresentação de resultados





Aspecto determinante para o sucesso do processo analítico

- A maior parte dos destinatários não são peritos
  - Apresentação clara
  - Conclusões objectivas e com fundamentação depurada dos aspectos científicos
  - Gráficos
  - Tabelas



- Sustentação teórica
  - Anexo com a descrição técnica dos modelos utilizados
  - Justificação científica para a utilização de cada um dos modelos





DADOS, INFORMAÇÃO, ANÁLISE DE DADOS, INVESTIGAÇÃO E ALGUMAS COISAS MAIS

MESTRADO EM ENGENHARIA INFORMÁTICA